

Projet de Séries Temporelles

Prévision des ventes de carburants

Approche en séries temporelles et enjeux de marché



DIOUF Salimata
KOUAME Christ Ange Dylan
OUATTARA Aboubakar
OUATTARA Souleymane

Enseignant : ROBERT Christian



Table des matières

Introduction	2
1 Analyse des ventes de supercarburants	2
1.1 Méthodologie globale de modélisation	2
1.2 Modélisation des données	3
1.2.1 Visualisation des données	3
1.2.2 Modélisation des résidus	4
1.2.3 Détermination du meilleur modèle	6
1.2.4 Validation historique du modèle	7
1.3 Prévisions des ventes de supercarburants à 12 mois	8
2 Analyse des ventes de gazole	9
2.1 Méthodologie appliquée	9
2.2 Modélisation des données	10
2.2.1 Visualisation des données	10
2.2.2 Méthode 1 : Ajustement d'un ARMA(p,q) sur le bruit	10
2.2.3 Méthode 2 : Ajustement d'un SARIMA(p,d,q)(P,D,Q)[s] sur la série	12
2.2.4 Choix du modèle entre les 2 méthodes	16
2.2.5 Prévisions	16
Conclusion	18

Introduction

Ce projet s'inscrit dans une problématique concrète de prévision des ventes de produits pétroliers en France, à partir de données mensuelles couvrant plus de quarante ans. L'objectif est de proposer une méthodologie robuste permettant d'anticiper l'évolution des ventes de supercarburants et de gazole à court terme.

D'un point de vue pratique, ce type de travail présente un réel intérêt en finance de marché et en économie de l'énergie, où la capacité à prévoir la demande est essentielle pour la gestion des stocks, la couverture des risques ou encore la valorisation des produits liés aux matières premières. Les méthodes de séries temporelles offrent ici un cadre particulièrement adapté pour exploiter la dynamique passée des données et en extraire des tendances prédictives fiables.

Afin de mener à bien ce projet, nous avons choisi de travailler en groupe de quatre en nous répartissant en deux sous-groupes : Dylan KOUAME et Salimata DIOUF sur les ventes de supercarburants, et Souleymane OUATTARA et Aboubakar OUATTARA sur celles de gazole. Cette organisation nous a permis d'approfondir les analyses tout en garantissant une participation active de chacun.

L'ensemble du travail a été réalisé sous R, depuis l'exploration des données jusqu'à la modélisation et la production des prévisions. La démarche adoptée repose sur une analyse progressive : transformation des données, décomposition des séries, modélisation de la composante stochastique et validation des modèles à l'aide de tests statistiques, avec pour objectif final de proposer des prévisions cohérentes et justifiées.

1 Analyse des ventes de supercarburants

1.1 Méthodologie globale de modélisation

La modélisation des ventes de supercarburants repose sur une approche progressive visant à isoler et à modéliser séparément les différentes composantes de la série temporelle.

Dans un premier temps, une transformation logarithmique a été appliquée à la série initiale (X_t) afin de stabiliser la variance et de travailler dans un cadre additif. On considère ainsi la décomposition suivante :

$$\log(X_t) = T_t + S_t + R_t$$

où T_t représente la tendance, S_t la composante saisonnière et R_t la composante résiduelle.

La décomposition de la série a été réalisée à l'aide de la méthode STL (*Seasonal-Trend decomposition using Loess*), qui permet d'obtenir une estimation robuste et flexible de la tendance et de la saisonnalité, sans imposer de structure paramétrique stricte. Le choix d'un modèle additif sur le logarithme s'est révélé particulièrement adapté compte tenu de la nature des données.

Une fois la tendance et la saisonnalité extraites, l'analyse s'est concentrée sur la composante résiduelle (R_t), supposée contenir l'information stochastique de la série. L'étude des fonctions d'autocorrélation (ACF) et d'autocorrélation partielle (PACF), combinée à des tests de stationnarité, a permis d'identifier une structure de dépendance temporelle modélisable par un processus ARMA(p, q) :

$$R_t = \sum_{i=1}^p \phi_i R_{t-i} + \sum_{j=1}^q \theta_j \varepsilon_{t-j} + \varepsilon_t$$

Le choix des ordres p et q a été guidé à la fois par l'analyse graphique, la significativité des coefficients estimés et la validation empirique des modèles candidats. Plusieurs modèles ont été comparés à l'aide de critères d'information et de tests statistiques, notamment les tests de Ljung-Box et de Box-Pierce appliqués aux résidus, afin de vérifier l'absence d'autocorrélation résiduelle.

Une étape de validation a également été menée en comparant les valeurs reconstruites à partir du modèle avec les données observées, permettant de confirmer la bonne adéquation du modèle retenu. Cette approche s'apparente à une forme de validation empirique ou de *backtesting*.

Enfin, les prévisions ont été obtenues en prolongeant la composante ARMA estimée, puis en réintégrant les composantes de tendance et de saisonnalité. Le retour à l'échelle initiale a été effectué par exponentiation :

$$\widehat{X}_t = \exp \left(\widehat{T}_t + \widehat{S}_t + \widehat{R}_t \right)$$

Cette méthodologie permet ainsi de capturer efficacement les différentes dimensions de la série et de produire des prévisions cohérentes avec la dynamique observée.

1.2 Modélisation des données

1.2.1 Visualisation des données

Nous commençons par représenter la série brute des ventes mensuelles de supercarburants afin d'en dégager les principales caractéristiques visuelles. Deux éléments apparaissent immédiatement. D'une part, on observe une rupture marquée autour de la fin de l'année 2019 et du début de l'année 2020, correspondant vraisemblablement au choc lié à la crise sanitaire. D'autre part, l'amplitude des fluctuations semble varier avec le niveau de la série, ce qui suggère que la variance n'est pas constante dans le temps.




FIGURE 1 – Série brute des ventes mensuelles de supercarburants

Cette observation nous a conduits à privilégier une approche de type multiplicatif. Afin de ramener la série dans un cadre additif plus simple à modéliser, nous avons appliqué une transformation logarithmique. La représentation de la série transformée montre alors des fluctuations d'amplitude beaucoup plus homogènes dans le temps, ce qui confirme la pertinence de ce choix.




FIGURE 2 – Série logarithmique des ventes de supercarburants

Une fois cette transformation effectuée, la série a été décomposée par la méthode STL afin d’estimer séparément la tendance, la saisonnalité et la composante résiduelle. Cette décomposition met en évidence une saisonnalité régulière et une tendance bien identifiée. La composante résiduelle apparaît globalement centrée autour de zéro et de faible amplitude, à l’exception du choc observé en 2020, ce qui confirme la cohérence de la décomposition retenue.




FIGURE 3 – Décomposition STL de la série logarithmique

1.2.2 Modélisation des résidus

Une fois la tendance et la saisonnalité extraites par la méthode STL, on s’intéresse à la composante résiduelle, notée (R_t) , qui représente la partie aléatoire de la série. L’objectif est de déterminer si ce bruit peut être assimilé à un bruit blanc, c’est-à-dire à une suite non autocorrélée, ou s’il subsiste une structure temporelle qu’il convient de modéliser.

Pour cela, nous avons examiné les fonctions d'autocorrélation (ACF) et d'autocorrélation partielle (PACF) de la série résiduelle, représentées aux figures 4 et 5. Ces graphiques montrent clairement que le bruit n'est pas un bruit blanc : plusieurs coefficients dépassent les bandes de confiance, ce qui traduit la présence d'une dépendance temporelle résiduelle. En revanche, on observe que les autocorrélations décroissent rapidement vers zéro, sans persistance de long terme. Ce comportement suggère que la série résiduelle reste stationnaire, même si elle n'est pas purement aléatoire.




FIGURE 4 – ACF de la série résiduelle des ventes de supercarburants




FIGURE 5 – PACF de la série résiduelle des ventes de supercarburants

Afin de confirmer cette impression visuelle, nous avons eu recours à deux tests complémentaires de stationnarité : le test de Dickey-Fuller augmenté (ADF) et le test KPSS. Leur intérêt est qu'ils reposent sur des hypothèses nulles opposées, ce qui permet d'obtenir un diagnostic plus robuste.

Le test ADF a pour hypothèse nulle la non-stationnarité de la série, autrement dit la présence d'une racine unitaire, tandis que son hypothèse alternative est la stationnarité. À l'inverse, le test KPSS prend pour hypothèse nulle la stationnarité de la série, contre l'hypothèse alternative de non-stationnarité. L'utilisation conjointe de ces deux tests permet donc de consolider la conclusion statistique.

Les résultats obtenus sur la série résiduelle sont résumés dans le tableau suivant :

Test	Hypothèse nulle H_0	Hypothèse alternative H_1	Résultat obtenu	Conclusion
ADF	Non-stationnarité	Stationnarité	statistique = -13.295 , p-value < 0.01	rejet de H_0
KPSS	Stationnarité	Non-stationnarité	statistique = 0.006861 , p-value > 0.10	non rejet de H_0

TABLE 1 – Résultats des tests de stationnarité appliqués à la série résiduelle

Ces deux résultats sont cohérents et conduisent à la même conclusion : la composante résiduelle est stationnaire. En particulier, le test ADF rejette très nettement l'hypothèse de non-stationnarité, tandis que le test KPSS ne remet pas en cause l'hypothèse de stationnarité. La série résiduelle n'est donc pas un bruit blanc, mais elle peut être modélisée dans le cadre d'un processus stationnaire.

Dans cette optique, nous retenons une modélisation de type ARMA pour représenter la dépendance temporelle restante. Les graphiques ACF et PACF permettent également de fixer un domaine de recherche raisonnable pour les ordres du modèle. L'ACF suggère de retenir une borne supérieure d'environ $q_{\max} = 5$, tandis que la PACF suggère une borne supérieure d'environ $p_{\max} = 6$. Ces valeurs servent de point de départ pour l'exploration des modèles ARMA candidats.

Afin d'affiner ce choix, nous avons adopté une approche empirique consistant à analyser la significativité des coefficients estimés, en particulier ceux associés aux retards les plus élevés. L'objectif est de partir d'un modèle relativement riche, puis de réduire progressivement ses ordres en vérifiant si les derniers coefficients restent statistiquement significatifs.

Les coefficients estimés pour le modèle retenu sont présentés dans le tableau suivant :

Coefficient	Valeur estimée	Écart-type
AR(1)	-0.2848	0.0432
AR(2)	-0.2106	0.0405
AR(3)	0.4010	0.0386
AR(4)	-0.4382	0.0404
AR(5)	-0.1613	0.0432
MA(1)	0.2475	0.0111
MA(2)	-0.2024	0.0118
MA(3)	-0.9798	0.0120

TABLE 2 – Coefficients estimés du modèle ARMA(5,3)

On constate que l'ensemble des coefficients, y compris ceux associés aux retards les plus élevés (AR(5) et MA(3)), sont significativement différents de zéro au regard de leurs écarts-types. Cela confirme qu'il n'est pas pertinent de réduire davantage les ordres du modèle.

1.2.3 Détermination du meilleur modèle

Afin de déterminer le modèle le plus adapté, nous avons estimé l'ensemble des modèles ARMA(p, q) avec $p \in [0, p_{\max}]$ et $q \in [0, q_{\max}]$, puis évalué la qualité de leurs résidus à l'aide de tests de bruit blanc.

L'objectif est de vérifier que les résidus du modèle ne contiennent plus de structure d'autocorrélation, condition essentielle pour valider la modélisation. Pour cela, nous avons utilisé les tests de Ljung-Box et de Box-Pierce, qui permettent de tester l'hypothèse nulle selon laquelle les autocorrélations des résidus sont nulles jusqu'à un certain lag.

Concrètement, ces tests reposent sur la somme des autocorrélations des résidus au carré jusqu'à un lag donné. Dans notre cas, compte tenu de la longueur de la série (environ 45 ans de données mensuelles), nous avons retenu un horizon de 9 ans, soit un lag de 108, afin de capter une éventuelle dépendance de moyen terme.

En fixant un seuil de significativité de 5%, un modèle est jugé acceptable si les p-values associées aux tests de Ljung-Box et de Box-Pierce sont supérieures à 0.05, ce qui signifie que l'on ne rejette pas l'hypothèse de bruit blanc des résidus.

Ce résultat est également confirmé par l'analyse graphique des résidus du modèle, réalisée à l'aide de la fonction `checkresiduals`. Cette approche permet d'évaluer simultanément plusieurs propriétés essentielles des résidus : leur centrage, leur distribution et l'absence d'autocorrélation résiduelle.




FIGURE 6 – Diagnostic des résidus du modèle ARMA(5, 3)

On observe que les résidus sont globalement centrés autour de zéro, avec une variance relativement stable sur l'ensemble de la période, à l'exception du choc ponctuel observé autour de 2020. L'histogramme suggère une distribution proche d'une loi gaussienne, malgré quelques valeurs extrêmes.

Par ailleurs, l'autocorrélogramme des résidus ne présente pas de structure marquée, la majorité des coefficients restant à l'intérieur des bandes de confiance. Cela confirme l'absence d'autocorrélation résiduelle significative.

1.2.4 Validation historique du modèle

Une fois le modèle ARMA(5,3) retenu pour la composante résiduelle de la série logarithmique, nous avons cherché à évaluer sa capacité à reconstituer correctement les données historiques. L'idée est simple : si le modèle est pertinent, alors, après réintégration de la tendance et de la saisonnalité puis retour à l'échelle initiale par exponentiation, la série reconstruite doit rester proche de la série effectivement observée.

Cette validation a d'abord été menée de manière visuelle, par superposition de la série observée et de la série reconstituée. Ce type de comparaison permet de vérifier rapidement si le modèle reproduit correctement les niveaux, la saisonnalité et la dynamique générale de la série.

Ventes observées vs série reconstituée




FIGURE 7 – Comparaison entre la série observée et la série reconstituée

La figure montre une très forte proximité entre les deux courbes sur l'ensemble de la période. Le modèle restitue correctement la tendance de long terme, la saisonnalité annuelle ainsi que les fluctuations de court terme. Même la rupture observée autour de 2020 reste globalement bien absorbée par la méthodologie retenue, sans qu'il soit nécessaire d'estimer séparément un modèle avant et après cette date.

Afin de compléter cette lecture graphique, nous avons calculé plusieurs indicateurs quantitatifs d'ajustement. Le coefficient de détermination R^2 mesure la part de la variabilité de la série expliquée par la reconstruction. La MAE (*Mean Absolute Error*) mesure l'erreur absolue moyenne, la RMSE (*Root Mean Squared Error*) pénalise davantage les écarts importants, tandis que le biais moyen permet de détecter une éventuelle surestimation ou sous-estimation systématique.

Indicateur	Valeur
MAE	26.61
RMSE	37.71
MAPE	2.82%
R^2	0.989
Biais moyen	2.47

TABLE 3 – Indicateurs d'ajustement entre la série observée et la série reconstituée

Ces résultats confirment la très bonne adéquation du modèle. En particulier, un R^2 proche de 1 et une erreur relative moyenne inférieure à 3% traduisent une excellente capacité de reconstruction. Le biais moyen, très faible, montre par ailleurs que le modèle ne présente pas d'erreur systématique marquée.

On peut donc conclure que la méthodologie adoptée (transformation logarithmique, décomposition STL et modélisation ARMA(5, 3) de la composante résiduelle) permet de reproduire fidèlement les données historiques. Cette étape de validation renforce la crédibilité du modèle et justifie son utilisation pour la construction des prévisions.

1.3 Prévisions des ventes de supercarburants à 12 mois

Une fois le modèle validé sur les données historiques, il peut être utilisé pour projeter l'évolution des ventes de supercarburants sur un horizon de 12 mois. Les prévisions sont obtenues en combinant trois composantes : la tendance (extrapolée à court terme), la saisonnalité (reproduite à partir du profil moyen mensuel) et la

composante stochastique modélisée par le processus ARMA(5, 3). Le passage à l'échelle initiale est ensuite effectué par exponentiation.

La figure suivante présente les prévisions obtenues ainsi que leurs intervalles de confiance à 95%.




FIGURE 8 – Prévisions des ventes de supercarburants à 12 mois et intervalles de confiance à 95%

Les résultats mettent en évidence une trajectoire globalement cohérente avec la dynamique récente de la série. On retrouve notamment une saisonnalité marquée, avec des fluctuations intra-annuelles bien reproduites, ainsi qu'une légère tendance haussière à court terme dans le prolongement de la reprise observée après 2020.

Les intervalles de confiance entourant les prévisions demeurent relativement resserrés. Leur largeur reflète l'incertitude associée à la composante aléatoire, ainsi que l'impact de chocs passés, en particulier la rupture observée en 2020. Malgré cela, l'incertitude relative demeure modérée, les bornes représentant environ une variation de l'ordre de $\pm 10\%$ autour des valeurs prévues, ce qui reste compatible avec un horizon de prévision de court terme.

D'un point de vue économique, ces résultats suggèrent une stabilisation progressive du marché des carburants, avec une dynamique désormais dominée par des effets saisonniers plutôt que par des chocs structurels. La capacité du modèle à intégrer implicitement l'impact de la rupture de 2020, sans nécessiter de traitement spécifique, renforce sa robustesse et sa pertinence dans une optique de prévision opérationnelle.

Ainsi, la méthodologie retenue permet de produire des projections cohérentes, exploitables dans un cadre décisionnel, notamment pour l'anticipation de la demande ou la gestion des approvisionnements sur le court terme.

2 Analyse des ventes de gazole

2.1 Méthodologie appliquée

Nous utiliserons deux méthodes, la première consistant à estimer un ARMA(p, q) sur le bruit (après donc avoir retiré la tendance et la saisonnalité), et la seconde consistant à estimer un SARIMA(p, d, q) (P, D, Q) [s] sur notre série.

Le choix de la méthode 1 repose sur le fait qu'on observe des autocorrélations dans les résidus (test de Ljung-Box), de ce fait nous ne sommes plus dans le cadre de la modélisation d'un processus stationnaire, raison pour laquelle on choisit ici de modéliser le résidu comme une composante à part, puis de modéliser les autres paramètres (la tendance par régression linéaire, et on rajoute la saisonnalité déterministe).

Le choix de la méthode 2 quant à lui, repose sur les observations faites sur les autocorrélogrammes de la série $\log(X_t)$, nécessitant donc plusieurs différenciations (ordinaire et saisonnière), pour tenir compte de la non-stationnarité et des effets saisonniers en présence.

2.2 Modélisation des données

2.2.1 Visualisation des données




FIGURE 9 – Evolution des ventes de gazole

L’observation initiale de la série brute montre une augmentation de l’amplitude des oscillations au fil du temps. Cette analyse nous permet de supposer que nous avons affaire à un modèle multiplicatif, nous avons donc opté pour une transformation logarithmique ($y_{gaz} = \log(X_t)$) afin de stabiliser la variance et de travailler dans un cadre additif. Nous procédons ensuite à une décomposition additive de la série transformée par la méthode des moyennes mobiles (fonction `decompose`)

2.2.2 Méthode 1 : Ajustement d’un ARMA(p,q) sur le bruit

Cette méthode suit la même logique de décomposition que celle utilisée pour le supercarburant. Les étapes et résultats spécifiques sont les suivants :

Transformation : Application du logarithme ($\log(VGAZOL)$) pour traiter la nature multiplicative de la série.

Décomposition : Extraction de la tendance et de la saisonnalité par moyenne mobile.

Analyse du bruit : Le résidu obtenu est stationnaire (Test de Phillips-Perron, p-value < 0.01) mais n’est pas un bruit blanc (Test de Ljung-Box significatif).

test	p-value
Augmented Dickey-Fuller test	<0.01
Box-Ljung test	2.2e-16

TABLE 4 – Test d’absence d’autocorrélation

Identification et validation ARMA : L'examen des fonctions d'autocorrélation (ACF/PACF) suggère un modèle de type ARMA(10,5) pour modéliser le résidu.

Nous allons donc fixer $p_{max} = 10$, $q_{max} = 5$ et effectuer une recherche par combinaison des nombres de paramètres afin de choisir le arma qui modélise le plus fidèlement notre résidu (en utilisant les critères AIC, BIC, MAE, RMSE) avec le moins de paramètres, tout en ayant des résidus qui sont des bruits blancs. La recherche nous ramène donc à considérer 3 modèles.

modèle	MAE	RMSE	AIC	BIC
ARMA(4,4)	0,04235535	0,02534067	-1802,803	-1760,131
ARMA(4,5)	0.04242861	0.02528303	-1799.772	-1752.833
ARMA(5,4)	0.04239235	0.02534038	-1800.510	-1753.570

TABLE 5 – Test d'absence d'autocorrélation

Selon les critères de l'AIC et du BIC, le modèle **arma(4,4)** apparaît comme le meilleur des modèles et est également celui avec le moins de paramètres.




FIGURE 10 – Autocorrélogramme et autocorrélogramme partiel du résidu

On vérifie si le modèle respecte les hypothèses des stationnarité du bruit et d'absence d'autocorrélations.

test	p-value
Box-Ljung test	0.03726
Box-Pierce test	0.2241
Augmented Dickey-Fuller test	<0.01

TABLE 6 – Tests d'absence d'autocorrélation et de stationnarité

Au vu des tests de stationnarités et d'absence d'autocorrélations, on peut conclure que les résidus du modèle sont bel et bien un bruit blanc.




FIGURE 11 – Diagnostic du modèle ARMA (4,4)

2.2.3 Méthode 2 : Ajustement d'un SARIMA(p,d,q)(P,D,Q)[s] sur la série

Nous allons ajuster un modèle SARIMA sur notre série $\log(X_t)$, et estimer les valeurs de p_{max} , q_{max} , P_{max} , Q_{max} , d et D à l'aide d'arguments basés sur l'ACF, le PACF et d'autres tests statistiques.

En représentant l'ACF de la série, on constate que les pics ne convergent pas vers 0 (ou une valeur significativement nulle), on peut donc conclure qu'il n'y a pas stationnarité ce qui nous contraint à différencier la série une première fois à l'ordre 1 :




FIGURE 12 – ACF de la série $\log(X_t)$

Après une première différenciation de la série, nous obtenons l'ACF suivant :




FIGURE 13 – ACF de la série différenciée à l'ordre 1

Sur la figure, nous constatons que les autocorrélations sont fortes pour les valeurs multiples de 12, il existe donc une saisonnalité annuelle que nous supprimerons en différenciant à l'ordre 12 (*i.e* $1 - L^{12}$).

Après avoir effectué cette seconde différenciation nous obtenons les résultats suivants :




FIGURE 14 – ACF et PACF de $(1 - L)(1 - L^{12}) \log(X_t)$

Les résultats obtenus ayant l'air satisfaisants, nous testons ensuite la stationnarité de notre nouvelle série à l'aide des tests statistiques ADF, Phillips-Perron et KPSS, dont les résultats sont présentés dans le tableau ci-dessous (le seuil de significativité retenu est de 5%) :

Test	Hypothèse nulle H_0	Hypothèse alternative H_1	Résultat obtenu	Conclusion
ADF	Non-stationnarité	Stationnarité	stat = -3.6962, $pvalue = 0.02419$	rejet de H_0
Phillips-Perron	Non-stationnarité	Stationnarité	stat = -46.171, $pvalue = 0.01$	rejet de H_0
KPSS	Stationnarité	Non-stationnarité	stat = 0.040425, $pvalue = 0.1$	non rejet de H_0

TABLE 7 – Résultats des tests de stationnarité appliqués à la série $(1 - L)(1 - L^{12}) \log(X_t)$

Les résultats de ces 3 tests confirment donc la stationnarité de $(1 - L)(1 - L^{12}) \log(X_t)$.

Identification et recherche des paramètres du SARIMA(p,d,q)(P,D,Q)[s] : A l'aide de l'ACF, du PACF et des conclusions tirées précédemment nous pouvons identifier les paramètres suivants pour notre modèle SARIMA :

- **p=2** et **q=4** : en effet, seuls les deux premiers pics du PACF et les quatre premiers pics de l'ACF (en ne comptant pas le premier) sont significativement différents de 0.

- **s=12** : en effet nous avons observé une saisonnalité à l'ordre 12 sur les autocorrélogrammes(d'où la différenciation avec $1 - L^s$ avec $s = 12$).
- **P=2** et **Q=2** : nous observons 2 pics multiples de $s = 12$ (12 et 24) qui sont significatifs sur le PACF et sur l'ACF, avant d'avoir les premiers pics multiples de 12 (en l'occurrence 36) non significatifs.
- **d=1** et **D=1** : nous différencions une seule fois pour intervenir sur la convergence des lags et la non stationnarité de la série (donc $d=1$) et nous différencions une seule fois à l'ordre 12 pour nous occuper de la saisonnalité annuelle (*i.e* $(1 - L)^d(1 - L^{12})^D = (1 - L)(1 - L^{12})$)

Le modèle initial sur lequel l'étude s'appuiera sera donc un **SARIMA(2,1,4)(2,1,2)[12]** (qui sera utilisé sur notre série $\log(X_t)$).

Etude de la significativité des coefficients du modèle initial : Avant de débiter une recherche de paramètres sur notre **SARIMA** basée sur p_{max} et q_{max} dans le but de minimiser le nombre de paramètres à étudier, nous devons d'abord valider notre modèle initial en étudiant la significativité des coefficients de ce modèle, en particulier ceux avec les retards les plus élevés (**ar2**, **ma4**, **sar2**, **sma2**), nous obtenons donc les résultats ci-dessous :

Coefficients	Estimate	Std. Error	z value	Pr(> z)	Significativité
ar1	-1.1579033	0.0022974	-504.0107	$< 2.2e-16$	***
ar2	-0.9988572	0.0016243	-614.9352	$< 2.2e-16$	***
ma1	0.5911649	0.0417983	14.1433	$< 2.2e-16$	***
ma2	0.1325724	0.0352140	3.7648	0.0001667	***
ma3	-0.8243759	0.0339043	-24.3148	$< 2.2e-16$	***
ma4	-0.2416714	0.0418972	-5.7682	$8.012e-09$	***
sar1	-0.5821995	0.2217904	-2.6250	0.0086649	**
sar2	-0.0372274	0.0608193	-0.6121	0.5404728	
sma1	-0.2193826	0.2187036	-1.0031	0.3158104	
sma2	-0.5604004	0.1966362	-2.8499	0.0043728	**

TABLE 8 – Coefficients estimés du modèle **SARIMA(2,1,4)(2,1,2)[12]**

Nous constatons que le coefficient **sar2** n'est pas significativement différent de 0, nous allons donc réduire la valeur du paramètre P de 2 à 1, notre nouveau modèle initial sera donc un **SARIMA(2,1,4)(1,1,2)[12]**, dont l'analyse de la significativité des coefficients est exposée ci-dessous :

Coefficients	Estimate	Std. Error	z value	Pr(> z)	Significativité
ar1	-1.1579291	0.0023003	-503.3852	$< 2.2e-16$	***
ar2	-0.9988858	0.0016087	-620.9402	$< 2.2e-16$	***
ma1	0.5921000	0.0417100	14.1956	$< 2.2e-16$	***
ma2	0.1326682	0.0353028	3.7580	0.0001713	***
ma3	-0.8245601	0.0339891	-24.2596	$< 2.2e-16$	***
ma4	-0.2427170	0.0417978	-5.8069	$6.363e-09$	***
sar1	-0.6648581	0.1864215	-3.5664	0.0003619	***
sma1	-0.1267381	0.1691135	-0.7494	0.4536004	
sma2	-0.6520171	0.1421142	-4.5880	$4.476e-06$	***

TABLE 9 – Coefficients estimés du modèle **SARIMA(2,1,4)(1,1,2)[12]**

Nous constatons cette fois-ci que les coefficients associés aux retards les plus élevés(**ar2**, **ma4**, **sar1**, **sma2**) sont tous significativement différents de 0, cela confirme qu'il n'est pas pertinent de réduire davantage les nouvelles valeurs maximales obtenues *i.e* $p_{max} = 2, q_{max} = 4, P_{max} = 1$ et $Q_{max} = 2$.

Détermination du meilleur modèle

Dans cette partie, nous recherchons tous les paramètres $(p, q, P, Q) \in [0, p_{max}] \times [0, q_{max}] \times [0, P_{max}] \times [0, Q_{max}]$ (les valeurs de d et D étant déjà fixées à 1), qui permettent d'avoir un meilleur modèle que notre

modèle initial (ou presque tout aussi efficace) en réduisant le nombre de paramètres à estimer. Les métriques d'évaluation sont principalement l'AIC et le BIC, néanmoins le RMSE et le MAE seront également analysés. Les modèles sont également sélectionnés selon le fait que leurs résidus soient des bruits blanc (tests de Ljung-Box et Box-Pierce).

Modèle	RMSE	MAE	AIC	BIC
ARIMA(2,1,4)(0,1,1)	0.055957	0.032475	-1485.533	-1451.411
ARIMA(2,1,4)(1,1,1)	0.055872	0.032398	-1485.277	-1446.889
ARIMA(2,1,4)(0,1,2)	0.055858	0.032377	-1485.573	-1447.185
ARIMA(2,1,4)(1,1,2)	0.055646	0.032038	-1487.284	-1444.631

TABLE 10 – Modèles retenus après optimisation

Le critère de l'AIC nous inciterait à choisir notre modèle de base mais celui du BIC nous fait pencher pour le modèle **SARIMA(2,1,4)(0,1,1)** [12], ce modèle possède également le plus petit nombre de paramètres ce qui est un avantage dans l'estimation, bien que les RMSE et MAE du modèle initial soient meilleurs (ce qui peut s'expliquer par le fait que le modèle possède plus de paramètres et peut donc surajuster plus facilement nos données).

L'AIC n'étant également pas discriminant, nous retiendront le modèle minimisant le BIC et le nombre de paramètres à estimer, c'est-à-dire le : **SARIMA(2,1,4)(0,1,1)** [12], et comme expliqué précédemment les résidus de ce modèle sont des bruits blancs, comme nous le constatons ci-dessous :




FIGURE 15 – Résidus du modèle **SARIMA(2,1,4)(0,1,1)** [12]

Test	Statistique	df	p-value
Box-Pierce	$X^2 = 115.62$	113	0.4141
Ljung-Box	$Q^* = 130.88$	113	0.1199


TABLE 11 – Tests Box-Pierce et Ljung-Box sur les résidus du modèle **SARIMA(2,1,4)(0,1,1)** [12]

Les p_{value} étant supérieures à 5%, les résidus n'ont donc pas d'autocorrélations d'ordre supérieur à 1. La valeur de la moyenne des résidus s'élève à -0.002967379 , ce qui confirme le centrage des résidus que nous observons sur la figure précédente, nous pouvons donc accepter l'hypothèse de blancheur des résidus.

2.2.4 Choix du modèle entre les 2 méthodes


Dans cette partie nous choisissons le modèle à conserver entre l'ARMA(4,4) de la méthode 1 et le SARIMA(2,1,4)(0,1,1)[12] de la méthode 2.

Pour se faire nous comparons les estimations obtenues par chaque modèle (sur la même plage d'années que nos données historiques) par rapport aux données réelles, nous utilisons ensuite plusieurs métriques d'évaluation pour conclure sur notre choix :



Métrique	Valeur
MAE	67.3508
RMSE	112.2248
MAPE (%)	3.3411
R^2	0.9749
Biais moyen	-9.7309

FIGURE 16 – Série observée vs série reconstituée SARIMA(2,1,4)(0,1,1)[12]



Métrique	Valeur
MAE	51.8573
RMSE	84.4710
MAPE (%)	2.5614
R^2	0.9854
Biais moyen	-2.1012

FIGURE 17 – Série observée vs série reconstituée ARMA(4,4)

2.2.5 Prévisions

Au vu des métriques obtenues et des figures précédentes, nous avons décidé de conserver le modèle ARMA(4,4), nous remarquerons qu'il tient également compte de la rupture qui a eu lieu en 2020 à cause de la crise sanitaire.




FIGURE 18 – Prévion de l'évolution des ventes de gazole

Conclusion

Ce projet nous a permis de mettre en œuvre une démarche complète de modélisation et de prévision appliquée à des séries économiques réelles, en l’occurrence les ventes de supercarburants et de gazole. Les méthodologies retenues, reposant notamment sur la transformation des données, leur décomposition et la modélisation de la composante résiduelle, ont permis d’obtenir des résultats globalement très satisfaisants, tant en termes d’ajustement que de qualité des prévisions. Les différents tests statistiques réalisés sur les résidus confirment l’adéquation des modèles retenus, ce qui renforce la crédibilité des projections obtenues.

Par ailleurs, ce travail nous a confrontés à des données présentant des phénomènes de rupture et de fortes variations, notamment autour de 2020. La méthodologie adoptée a permis d’intégrer ces particularités sans remettre en cause la cohérence globale des modèles. Au-delà des résultats obtenus, ce projet nous a ainsi permis de mieux appréhender les enjeux pratiques liés à la modélisation de séries temporelles économiques et l’importance d’une démarche rigoureuse pour produire des prévisions fiables et interprétables.

Annexes

A Script R : Modélisation des ventes de supercarburants

A.1 Chargement des bibliothèques

```
1 library(readr)
2 library(forecast)
3 library(tseries)
4 library(ggplot2)
5 library(AST)
6 library(lmtest)
7 library(FinTS)
```

A.2 Chargement et préparation des données

```
1 data <- read.csv("C:/Users/dylan/Documents/Disque local/ISFA/Data.csv",
2                 sep = ";",
3                 header = TRUE,
4                 check.names = FALSE)
5
6 data <- data[-1, ]
7 data <- data[nrow(data):1, ]
8 data <- data[-(1:12), ]
9 data[, -1] <- lapply(data[, -1], as.numeric)
```

A.3 Création des séries temporelles

```
1 ts_super <- ts(data[["5.2 Ventes de supercarburants auto (en kt)"]],
2               start = c(1981, 1),
3               frequency = 12)
4
5 log_super <- log(ts_super)
```

A.4 Décomposition STL et extraction de la composante résiduelle

```
1 stl_super <- stl(log_super, s.window = "periodic")
2 super_deseason_detrend <- stl_super$time.series[, "remainder"]
```

A.5 Tests de stationnarité

```
1 adf.test(na.omit(super_deseason_detrend))
2 kpss.test(na.omit(super_deseason_detrend))
```

A.6 Estimation initiale du modèle ARMA

```
1 modele_arma <- arima(super_deseason_detrend, order = c(5,0,3))
2 modele_arma
```

A.7 Comparaison des modèles ARMA candidats

```
1 results <- data.frame()
2
3 for(p in 0:5){
4   for(q in 0:3){
5
6     model <- try(arima(super_deseason_detrend,
7                       order = c(p,0,q)),
8                 silent = TRUE)
9
10    if(!inherits(model, "try-error")){
11
12      lb <- Box.test(residuals(model),
13                    lag = 108,
14                    type = "Ljung-Box",
15                    fitdf = p + q)
16
17      bp <- Box.test(residuals(model),
18                    lag = 108,
19                    type = "Box-Pierce",
20                    fitdf = p + q)
21
22      results <- rbind(results,
23                      data.frame(
24                        p = p,
25                        q = q,
26                        AIC = AIC(model),
27                        LjungBox_pvalue = lb$p.value,
28                        BoxPierce_pvalue = bp$p.value
29                      ))
30    }
31  }
32 }
33
34 results
```

A.8 Sélection des modèles admissibles

```
1 subset(results,
2         LjungBox_pvalue > 0.05 &
3         BoxPierce_pvalue > 0.05)
```

A.9 Validation hors échantillon

```
1 train <- window(super_deseason_detrend, end = c(2019,12))
2 test  <- window(super_deseason_detrend, start = c(2020,1))
3
4 modele_arma <- arima(train, order = c(5,0,3))
5
6 pred <- forecast(modele_arma, h = length(test))
7 errors <- test - pred$mean
8
9 MAE <- mean(abs(errors), na.rm = TRUE)
10 RMSE <- sqrt(mean(errors^2, na.rm = TRUE))
11
```

```
12 MAE
13 RMSE
```

A.10 Diagnostic global des résidus

```
1 modele_arma <- arima(super_deseason_detrend, order = c(5,0,3))
2 checkresiduals(modele_arma)
```

A.11 Racines du modèle

```
1 roots_ar <- polyroot(c(1, -modele_arma$model$phi))
2 roots_ma <- polyroot(c(1, modele_arma$model$theta))
3
4 Mod(roots_ar)
5 Mod(roots_ma)
```

A.12 Reconstruction de la série initiale

```
1 trend_super <- stl_super$time.series[, "trend"]
2 season_super <- stl_super$time.series[, "seasonal"]
3
4 modele_arma_super <- arima(super_deseason_detrend, order = c(5,0,3))
5
6 arma_fitted_super <- super_deseason_detrend - residuals(modele_arma_super)
7
8 log_super_hat <- trend_super + season_super + arma_fitted_super
9 super_hat <- exp(log_super_hat)
```

A.13 Indicateurs d'ajustement

```
1 obs <- ts_super
2 pred <- super_hat
3
4 valid <- complete.cases(obs, pred)
5 obs <- obs[valid]
6 pred <- pred[valid]
7
8 errors <- obs - pred
9
10 MAE <- mean(abs(errors))
11 RMSE <- sqrt(mean(errors^2))
12 MAPE <- mean(abs(errors / obs)) * 100
13 R2 <- 1 - sum(errors^2) / sum((obs - mean(obs))^2)
14 BIAS <- mean(errors)
15
16 results <- data.frame(
17   MAE = MAE,
18   RMSE = RMSE,
19   MAPE_percent = MAPE,
20   R2 = R2,
21   Bias = BIAS
22 )
23
24 results
```

A.14 Prévisions à 12 mois

```
1 trend_super <- stl_super$time.series[, "trend"]
2 season_super <- stl_super$time.series[, "seasonal"]
3 remainder_super <- stl_super$time.series[, "remainder"]
4
5 modele_arma_super <- arima(remainder_super, order = c(5,0,3))
6
7 h <- 12
8 pred_arma <- predict(modele_arma_super, n.ahead = h)
9
10 arma_mean <- as.numeric(pred_arma$pred)
11 arma_se <- as.numeric(pred_arma$se)
12
13 n_trend_window <- 60
14 n <- length(trend_super)
15
16 trend_train <- trend_super[(n - n_trend_window + 1):n]
17 t_train <- 1:length(trend_train)
18
19 trend_lm <- lm(trend_train ~ t_train)
20
21 t_future <- (length(trend_train) + 1):(length(trend_train) + h)
22 pred_trend <- predict(trend_lm,
23                      newdata = data.frame(t_train = t_future),
24                      se.fit = TRUE)
25
26 trend_mean <- as.numeric(pred_trend$fit)
27 trend_se <- as.numeric(pred_trend$se.fit)
28
29 season_pattern <- tapply(season_super, cycle(season_super), mean)
30
31 end_year <- end(ts_super)[1]
32 end_month <- end(ts_super)[2]
33
34 future_months <- ((end_month + (1:h) - 1) %% 12) + 1
35 season_mean <- as.numeric(season_pattern[future_months])
36
37 log_forecast_mean <- trend_mean + season_mean + arma_mean
38 log_forecast_se <- sqrt(trend_se^2 + arma_se^2)
39
40 log_lower95 <- log_forecast_mean - 1.96 * log_forecast_se
41 log_upper95 <- log_forecast_mean + 1.96 * log_forecast_se
42
43 forecast_mean <- exp(log_forecast_mean + 0.5 * log_forecast_se^2)
44 lower95 <- exp(log_lower95)
45 upper95 <- exp(log_upper95)
46
47 future_dates <- seq(as.Date("2025-12-01"), by = "month", length.out = h)
48
49 table_previsions <- data.frame(
50   Date = future_dates,
51   Forecast_kt = round(forecast_mean, 2),
52   Lower_95_kt = round(lower95, 2),
53   Upper_95_kt = round(upper95, 2)
54 )
55
56 table_previsions
```

B Script R : Modélisation des ventes de Gazole

B.1 Chargement des données

```
1 library(readr)
2 library(dplyr)
3
4 df <- read.csv("C:\\COURS ET ANNALES ISFA\\Series temporelles\\Data.csv",
5               skip = 1,      # saute la 1re ligne
6               header = TRUE,
7               sep=";")
8
9
10 str(df)
11 head(df)
12 summary(df)
```

B.2 Récupération de la variable à prédire

```
1 library(lubridate)
2
3 df <- df |>
4   mutate(PERIODE = ym(PERIODE)) |>
5   arrange(PERIODE)
6
7 y_gaz <- ts(df$VGAZOL_RAFF,
8            start = c(1980, 1), frequency = 12)
```

B.3 Visualisation graphique et quelques statistiques

```
1 plot(y_gaz, main = "Ventes de gazole auto", ylab = "kt")
2 boxplot(y_gaz ~ cycle(y_gaz), main = "Saisonnalité", xlab = "Mois", ylab = "kt")
3
4 summary(y_gaz)
5 tapply(as.numeric(y_gaz), cycle(y_gaz), mean, na.rm = TRUE)
```

B.4 Décomposition de la série

```
1 y_gaz <- log(y_gaz) #modele multiplicatif donc on prend log
2
3 decomp_gaz <- decompose(y_gaz, type = "additive") #Donc decomposition additive
4   comme vu plus haut
5 plot(decomp_gaz)
6
7 decomp_gaz$trend
8 sum(decomp_gaz$seasonal[1:12]) # Verifier de la condition d'identifiabilité de la
9   saisonnalité
10
11 mean(decomp_gaz$random, na.rm = TRUE) #Le bruit est censé être centré en 0
12 sd(decomp_gaz$random, na.rm = TRUE)
```

B.5 Vérification de la stationnarité de la série

```
1 y_gaz_clean <- y_gaz[!is.na(y_gaz)]
2 acf(y_gaz_clean, lag.max = 120,
3     main = "ACF des residus (sans NA) de y_gaz")
```

B.6 Méthode 1 : ajustement d'un ARMA(p,q) sur le bruit

B.6.1 Transformation de la série : retrait du trend et de la saisonnalité

```
1
2 dy_gaz <- y_gaz - decomp_gaz$trend
3 plot(dy_gaz, main = "Difference premiere de y_gaz", ylab = "dy_gaz", xlab = "Temps"
4      )
5 # 3. ACF et PACF de la serie differenciee
6 dy_gaz_clean <- dy_gaz[!is.na(dy_gaz)]
7 acf(dy_gaz_clean, #lag.max = 120, main = "ACF de dy_gaz")
8 pacf(dy_gaz_clean, #lag.max = 120, main = "PACF de dy_gaz")
```

B.6.2 Vérification de la non stationnarité de la série

```
1
2 library(tseries)
3 adf_dy_gaz <- adf.test(dy_gaz_clean, k = 120)
4 adf_dy_gaz
```

B.6.3 Traitement de la saisonnalité

```
1
2 dsy_gaz <- dy_gaz - decomp_gaz$seasonal
3 # 2. Representation de la serie differenciee
4 plot(dsy_gaz, main = "dy_gaz desaisonnalisee", ylab = "dsy_gaz", xlab = "Temps")
```

B.6.4 ACF et PACF de la série détendancialisée et désaisonnalisée

```
1
2 # 3. ACF de la serie desaisonnalisee
3 dsy_gaz_clean <- dsy_gaz[!is.na(dsy_gaz)]
4 acf(dsy_gaz_clean, #lag.max = 120, main = "ACF de dsy_y_gaz")
5 pacf(dsy_gaz_clean, #lag.max = 120, main = "PACF de dsy_gaz")
```

B.6.5 Test de stationnarité

```
1
2 library(tseries)
3 adf_dsy_gaz <- adf.test(dsy_gaz_clean, k=60)
4 adf_dsy_gaz
```

```

1 library(tseries)
2 library(zoo)
3 #1. Nettoyage des NA (interpolation)
4 y_gaz_pp_vec <- na.approx(as.numeric(dsy_gaz))
5
6 y_gaz_pp_ts <- ts(y_gaz_pp_vec, start = start(dsy_gaz), frequency = frequency(
7   dsy_gaz))
8
9 #2. Test de Phillips-Perron
10 pp_y_gaz <- pp.test(y_gaz_pp_ts,
11   alternative = "stationary", # H1 : stationnaire
12   type = "Z(t_alpha)") # statistique disponible
13 pp_y_gaz

```

```

1 library(tseries)
2 library(zoo)
3
4 #1. Nettoyer les NA
5 y_gaz_kpss_vec <- na.approx(as.numeric(dsy_gaz))
6 y_gaz_kpss_ts <- ts(y_gaz_kpss_vec, start = start(dsy_gaz), frequency = frequency(
7   dsy_gaz))
8
9 #2. Test KPSS avec stationnarite autour d'une tendance
10 kpss_y_gaz_trend <- kpss.test(y_gaz_kpss_ts, null = "Trend")
11 kpss_y_gaz_trend

```

B.6.6 Vérification des autocorrélations des résidus

```

1 Box.test(dsy_gaz_clean, lag = 120, type = "Box-Pierce")

```

B.6.7 Analyse automatique du meilleur ARMA avec le moins de paramètres à estimer

```

1 library(forecast)
2 library(dplyr)
3 library(knitr)
4
5
6 x <- dsy_gaz_clean
7 x <- x[!is.na(x)]
8
9 p_max <- 5
10 q_max <- 10
11
12 results <- expand.grid(p = 0:p_max,
13   q = 0:q_max) |>
14   rowwise() |>
15   mutate(
16     fit = list(
17       tryCatch(
18         Arima(x, order = c(p, 0, q), seasonal = c(0, 0, 0)),
19         error = function(e) NULL
20       )
21     ),

```

```

22   AIC = if (!is.null(fit)) AIC(fit) else NA_real_,
23   BIC = if (!is.null(fit)) BIC(fit) else NA_real_
24 ) |>
25 ungroup() |>
26 filter(!is.na(AIC), !is.na(BIC)) |>
27 select(-fit) |>
28 arrange(BIC)
29
30 # Les 5 meilleurs modeles selon le BIC (avec leur AIC)
31 top_models <- head(results, 5)

```

```

1 library(forecast)
2 library(dplyr)
3
4 # Serie stationnaire
5 x <- dsy_gaz_clean
6 x <- x[!is.na(x)]
7
8 # 1. Estimation des 3 modeles
9 arma_44 <- Arima(x, order = c(4, 0, 4), seasonal = c(0, 0, 0))
10 arma_45 <- Arima(x, order = c(4, 0, 5), seasonal = c(0, 0, 0))
11 arma_54 <- Arima(x, order = c(5, 0, 4), seasonal = c(0, 0, 0))
12
13 # 2. Fonction d'extraction RMSE/MAE/AIC/BIC
14 get_stats <- function(mod) {
15   acc <- accuracy(mod)
16   # La premiere ligne correspond au training set
17   rmse <- acc[1, "RMSE"]
18   mae <- acc[1, "MAE"]
19   aic <- AIC(mod)
20   bic <- BIC(mod)
21   c(RMSE = rmse, MAE = mae, AIC = aic, BIC = bic)
22 }
23
24 # 3. Construction du tibble
25 errors_tbl <- tibble(
26   modele = c("ARMA(4,4)", "ARMA(4,5)", "ARMA(5,4)")
27 ) |>
28   bind_cols(
29     as_tibble(
30       t(
31         apply(list(arma_44, arma_45, arma_54), get_stats)
32       )
33     )
34   )
35
36 errors_tbl

```

B.6.8 Analyse du modèle final

```

1 coeftest(arma_44)
2 arma_44 <- Arima(x, order = c(4, 0, 4), seasonal = c(0, 0, 0))
3 # Residus
4 res_m2 <- residuals(arma_44)
5
6
7 par(mfrow = c(2,2))

```

```

8 plot(res_m2, main = "Residus du modele ARIMA")
9 #acf(res_m2, lag.max = 48, main = "ACF des residus")
10 #pacf(res_m2, lag.max = 48, main = "PACF des residus")
11 qqnorm(res_m2); qqline(res_m2)
12 par(mfrow = c(1,1))
13
14 # Test de Ljung-Box : autocorrelation residuelle globale
15 Box.test(res_m2, lag = 120, type = "Ljung-Box", fitdf = length(coef(arma_44)))
16 Box.test(res_m2, lag = 120, type = "Box-Pierce", fitdf = length(coef(arma_44)))
17
18 # ou avec forecast :
19 checkresiduals(arma_44, lag=120)
20 mean ( sarima $ residuals )

```

B.6.9 Prévisions du modèle final

```

1
2 # =====
3 # PREVISIONS A 12 MOIS DES VENTES DE GAZOLE
4 # en reprenant les variables du script actuel
5 # =====
6
7 library(forecast)
8
9 # -----
10 # 1) Objets deja construits
11 # -----
12 # y_gaz          : serie log-transformee
13 # decomp_gaz     : decomposition additive de y_gaz
14 # dsy_gaz_clean  : serie log, detrendee et desaisonnalisée
15 # arma_44        : modele ARMA(4,4) retenu
16
17 # -----
18 # 2) Extraire tendance et saisonnalite
19 # -----
20 trend_gaz <- decomp_gaz$trend
21 season_gaz <- decomp_gaz$seasonal
22
23 # -----
24 # 3) Prevision de la composante ARMA a 12 mois
25 # -----
26 h <- 12
27 pred_arma <- predict(arma_44, n.ahead = h)
28
29 arma_mean <- as.numeric(pred_arma$pred)
30 arma_se <- as.numeric(pred_arma$se)
31
32 # -----
33 # 4) Prevision de la tendance
34 # Regression lineaire sur les 60 derniers mois non manquants
35 # -----
36 trend_gaz_clean <- trend_gaz[!is.na(trend_gaz)]
37
38 n_trend_window <- 60
39 n <- length(trend_gaz_clean)
40
41 trend_train <- trend_gaz_clean[(n - n_trend_window + 1):n]
42 t_train <- 1:length(trend_train)

```

```

43 trend_lm <- lm(trend_train ~ t_train)
44
45
46 t_future <- (length(trend_train) + 1):(length(trend_train) + h)
47 pred_trend <- predict(trend_lm,
48                       newdata = data.frame(t_train = t_future),
49                       se.fit = TRUE)
50
51 trend_mean <- as.numeric(pred_trend$fit)
52 trend_se <- as.numeric(pred_trend$se.fit)
53
54 # -----
55 # 5) Prevision de la saisonnalite
56 #   On repete le profil mensuel moyen
57 # -----
58 season_pattern <- tapply(season_gaz, cycle(y_gaz), mean, na.rm = TRUE)
59
60 end_year <- end(y_gaz)[1]
61 end_month <- end(y_gaz)[2]
62
63 future_months <- ((end_month + (1:h) - 1) %% 12) + 1
64 season_mean <- as.numeric(season_pattern[future_months])
65
66 # -----
67 # 6) Reconstruction sur l'echelle log
68 # -----
69 log_forecast_mean <- trend_mean + season_mean + arma_mean
70
71 # Approximation de l'ecart-type total sur l'echelle log
72 log_forecast_se <- sqrt(trend_se^2 + arma_se^2)
73
74 # Bornes 95%
75 log_lower95 <- log_forecast_mean - 1.96 * log_forecast_se
76 log_upper95 <- log_forecast_mean + 1.96 * log_forecast_se
77
78 # -----
79 # 7) Retour a l'echelle initiale
80 #   avec correction du biais de retransformation
81 # -----
82 forecast_mean <- exp(log_forecast_mean + 0.5 * log_forecast_se^2)
83 lower95 <- exp(log_lower95)
84 upper95 <- exp(log_upper95)
85
86 # -----
87 # 8) Tableau des previsions
88 # -----
89 future_dates <- seq(as.Date("2025-12-01"), by = "month", length.out = h)
90
91 table_previsions_gaz <- data.frame(
92   Date = future_dates,
93   Forecast_kt = round(forecast_mean, 2),
94   Lower_95_kt = round(lower95, 2),
95   Upper_95_kt = round(upper95, 2)
96 )
97
98 print(table_previsions_gaz)
99
100 # -----
101 # 9) Objets ts pour le graphique

```

```

102 # -----
103 forecast_ts <- ts(forecast_mean, start = c(2025, 12), frequency = 12)
104 lower_ts    <- ts(lower95,      start = c(2025, 12), frequency = 12)
105 upper_ts    <- ts(upper95,      start = c(2025, 12), frequency = 12)
106
107 # -----
108 # 10) Graphique : serie observee + previsions
109 # -----
110 ylim_all <- range(c(exp(y_gaz), forecast_ts, lower_ts, upper_ts), na.rm = TRUE)
111
112 plot(exp(y_gaz),
113      xlim = c(start(exp(y_gaz))[1], end(forecast_ts)[1] + (end(forecast_ts)[2]-1)/
114              12),
115      ylim = ylim_all,
116      main = "Ventes observees et previsions de gazole sur 12 mois",
117      ylab = "kt",
118      xlab = "Temps",
119      col = "black",
120      lwd = 1.5)
121
122 # relier la derniere observation a la premiere prevision
123 last_obs_time <- time(exp(y_gaz))[length(exp(y_gaz))]
124 last_obs_value <- tail(exp(y_gaz), 1)
125
126 first_fc_time <- time(forecast_ts)[1]
127 first_fc_value <- forecast_ts[1]
128
129 segments(x0 = last_obs_time, y0 = last_obs_value,
130          x1 = first_fc_time, y1 = first_fc_value,
131          col = "red", lwd = 2)
132
133 lines(forecast_ts, col = "red", lwd = 2)
134 lines(lower_ts, col = "blue", lty = 2, lwd = 1.5)
135 lines(upper_ts, col = "blue", lty = 2, lwd = 1.5)
136
137 legend("topleft",
138       legend = c("Observee", "Prevision", "IC 95%"),
139       col = c("black", "red", "blue"),
140       lty = c(1, 1, 2),
141       lwd = c(1.5, 2, 1.5),
142       bty = "n")

```

```

1 # =====
2 # GRAPHIQUE ZOOMÉ À PARTIR DE 2017
3 # serie observee + previsions + IC 95%
4 # =====
5
6 # fenetre observee a partir de 2017
7 obs_2017 <- window(exp(y_gaz), start = c(2017, 1))
8
9 # bornes de l'axe y
10 ylim_all <- range(c(obs_2017, forecast_ts, lower_ts, upper_ts), na.rm = TRUE)
11
12 plot(obs_2017,
13      xlim = c(2017, end(forecast_ts)[1] + (end(forecast_ts)[2]-1)/12),
14      ylim = ylim_all,
15      main = "Ventes observees et previsions de gazole a partir de 2017",
16      ylab = "kt",
17      xlab = "Temps",

```

```

18     col = "black",
19     lwd = 1.5)
20
21 # relier la dernière observation à la première prévision
22 last_obs_time <- time(exp(y_gaz))[length(exp(y_gaz))]
23 last_obs_value <- tail(exp(y_gaz), 1)
24
25 first_fc_time <- time(forecast_ts)[1]
26 first_fc_value <- forecast_ts[1]
27
28 segments(x0 = last_obs_time, y0 = last_obs_value,
29          x1 = first_fc_time, y1 = first_fc_value,
30          col = "red", lwd = 2)
31
32 # tracer les prévisions et les IC
33 lines(forecast_ts, col = "red", lwd = 2)
34 lines(lower_ts, col = "blue", lty = 2, lwd = 1.5)
35 lines(upper_ts, col = "blue", lty = 2, lwd = 1.5)
36
37 # ligne verticale au début des prévisions
38 abline(v = first_fc_time, col = "darkgray", lty = 3)
39
40 legend("bottomleft",
41       legend = c("Observée", "Prévision", "IC 95%"),
42       col = c("black", "red", "blue"),
43       lty = c(1, 1, 2),
44       lwd = c(1.5, 2, 1.5),
45       bty = "n")

```

B.7 Méthode 2 : Ajustement d'un SARIMA(p,d,q)(P,D,Q)[s] sur la série

B.7.1 Transformation de la série : différenciation ordinaire

```

1 # 1. Difference d'ordre 1 (detendancialisation)
2 dy_gaz <- diff(y_gaz, differences = 1)
3 dy_gaz
4
5 # 2. Representation de la serie differenciee
6 plot(dy_gaz,
7      main = "Difference premiere de y_gaz",
8      ylab = " dy_gaz", xlab = "Temps")
9
10 # 3. ACF de la serie differenciee
11 dy_gaz_clean <- dy_gaz[!is.na(dy_gaz)]
12
13 acf(dy_gaz_clean,
14     lag.max = 120,
15     main = "ACF de dy_gaz")

```

B.7.2 Vérification de la non stationnarité de la série différenciée(test ADF)

```

1 library(tseries)
2 adf_dy_gaz <- adf.test(dy_gaz_clean, k = 120)
3 adf_dy_gaz

```

B.7.3 Transformation de la série : différenciation saisonnière

```
1 dsy_gaz <- diff(dy_gaz, lag = 12, differences = 1)
2 dsy_gaz
3
4 # 2. Representation de la serie differenciee
5 plot(dsy_gaz,
6      main = "dy_gaz desaisonnalisée",
7      ylab = "dsy_gaz", xlab = "Temps")
8
9 # 3. ACF de la serie desaisonnalisée
10 dsy_gaz_clean <- dsy_gaz[!is.na(dsy_gaz)]
11
12 acf(dsy_gaz_clean,
13     lag.max = 120,
14     main = "ACF de dsy_gaz")
15
16 pacf(dsy_gaz_clean,
17     lag.max = 120,
18     main = "PACF de dsy_gaz")
```

B.7.4 Tests de stationnarité

```
1 adf_dsy_gaz <- adf.test(dsy_gaz_clean, k=60)
2 adf_dsy_gaz
```

```
1 library(zoo)
2
3 # 1. Nettoyage des NA (interpolation)
4 y_gaz_pp_vec <- na.approx(as.numeric(dsy_gaz))
5
6 y_gaz_pp_ts <- ts(y_gaz_pp_vec,
7                  start = start(dsy_gaz),
8                  frequency = frequency(dsy_gaz))
9
10 # 2. Test de Phillips-Perron
11 pp_y_gaz <- pp.test(y_gaz_pp_ts,
12                    alternative = "stationary", # H1 : stationnaire
13                    type = "Z(t_alpha)")      # statistique disponible
14 pp_y_gaz
```

```
1 library(zoo)
2
3 ## 1. Nettoyer les NA (comme pour ADF/PP)
4 y_gaz_kpss_vec <- na.approx(as.numeric(dsy_gaz))
5
6 y_gaz_kpss_ts <- ts(y_gaz_kpss_vec,
7                    start = start(dsy_gaz),
8                    frequency = frequency(dsy_gaz))
9
10 ## 2. Test KPSS avec stationnarite autour d'une tendance
11 kpss_y_gaz_trend <- kpss.test(y_gaz_kpss_ts,
12                              null = "Trend") # H0 : stationnaire autour d'une
13                                             tendance
14 kpss_y_gaz_trend
15
16 ## 3. (Optionnel) KPSS avec stationnarite autour d'une constante
```

```

16 kpss_y_gaz_level <- kpss.test(y_gaz_kpss_ts,
17                               null = "Level") # H0 : stationnaire autour d'une
                                                moyenne constante
18 kpss_y_gaz_level

```

B.7.5 Recherche du modèle initial

```

1 sarima <- Arima(y_gaz_clean, order = c(2, 1, 4), seasonal = list(order=c(2, 1, 2),
  period=12)) #modele d termine par analyse de l'ACF et du PACF
2 coeftest(sarima)

```

```

1 sarima <- Arima(y_gaz_clean, order = c(2, 1, 4), seasonal = list(order=c(1, 1, 2),
  period=12)) #modele ajuste conformement l'ancien coeftest
2 coeftest(sarima)

```

B.7.6 Recherche d'un modèle efficace comportant moins de paramètres à estimer

```

1 library(forecast)
2 library(dplyr)
3 library(knitr)
4
5 x <- y_gaz_clean
6 x <- x[!is.na(x)]
7
8 p_max <- 2
9 q_max <- 4
10 P_max <- 1
11 Q_max <- 2
12
13 results <- expand.grid(p = 0:p_max,
14                       q = 0:q_max,
15                       P = 0:P_max,
16                       Q = 0:Q_max) |>
17   rowwise() |>
18   mutate(
19     fit = list(
20       tryCatch(
21         Arima(x, order = c(p, 1, q), seasonal = list(order = c(P, 1, Q), period =
22           12)),
23         error = function(e) NULL
24       ),
25     AIC = if (!is.null(fit)) AIC(fit) else NA_real_,
26     BIC = if (!is.null(fit)) BIC(fit) else NA_real_,
27
28     LjungBox_pvalue = if (!is.null(fit)) tryCatch(
29       Box.test(residuals(fit), lag = 120, type = "Ljung-Box")$p.value,
30       error = function(e) NA_real_
31     ) else NA_real_,
32
33     BoxPierce_pvalue = if (!is.null(fit)) tryCatch(
34       Box.test(residuals(fit), lag = 120, type = "Box-Pierce")$p.value,
35       error = function(e) NA_real_
36     ) else NA_real_
37   ) |>
38   ungroup() |>

```

```

39   filter(!is.na(AIC), !is.na(BIC)) |>
40   select(-fit) |>
41   arrange(BIC)
42
43 # Les 5 meilleurs modeles selon le BIC (avec leur AIC)
44 top_models <- head(results, 5)
45 results
46
47 results_BB <- subset(results,
48                       LjungBox_pvalue > 0.05 &
49                       BoxPierce_pvalue > 0.05)
50 results_BB

```

```

1  library(forecast)
2  library(dplyr)
3
4  # Serie stationnaire
5  x <- y_gaz_clean
6  x <- x[!is.na(x)]
7
8  # 1. Estimation des 4 modeles
9  arima_2401 <- Arima(x, order = c(2, 1, 4), seasonal = list(order = c(0, 1, 1),
10 period=12))
11 arima_2411 <- Arima(x, order = c(2, 1, 4), seasonal = list(order = c(1, 1, 1),
12 period=12))
13 arima_2402 <- Arima(x, order = c(2, 1, 4), seasonal = list(order=c(0, 1, 2),period
14 =12))
15 arima_2412 <- Arima(x, order = c(2, 1, 4), seasonal = list(order=c(1, 1, 2),period
16 =12))
17
18 # 2. Fonction d'extraction RMSE/MAE/AIC/BIC
19 get_stats <- function(mod) {
20   acc <- accuracy(mod)
21   # La premiere ligne correspond au training set
22   rmse <- acc[1, "RMSE"]
23   mae <- acc[1, "MAE"]
24   aic <- AIC(mod)
25   bic <- BIC(mod)
26   c(RMSE = rmse, MAE = mae, AIC = aic, BIC = bic)
27 }
28
29 # 3. Construction du tibble
30 errors_tbl <- tibble(
31   modele = c( "ARIMA(2,1,4)(0,1,1)", "ARIMA(2,1,4)(1,1,1)", "ARIMA(2,1,4)(0,1,2)",
32               "ARIMA(2,1,4)(1,1,2)" )
33 ) |>
34   bind_cols(
35     as_tibble(
36       t(
37         sapply(list( arima_2401, arima_2411, arima_2402, arima_2412), get_stats)
38       )
39     )
40   )
41 errors_tbl

```

B.7.7 Analyse du modèle retenu

```

1 sarima <- Arima(y_gaz_clean, order = c(2, 1, 4), seasonal = list(order=c(0, 1, 1),
2   period=12))
3
4
5 coeftest(sarima)
6
7
8 # Residus
9 res_m2 <- residuals(sarima)
10
11 par(mfrow = c(2,2))
12 plot(res_m2, main = "Residus du modele ARIMA")
13 qqnorm(res_m2); qqline(res_m2)
14 par(mfrow = c(1,1))
15
16 # Test de Ljung-Box : autocorrelation residuelle globale
17 Box.test(res_m2, lag = 120, type = "Ljung-Box", fitdf = length(coef(sarima)))
18 Box.test(res_m2, lag = 120, type = "Box-Pierce", fitdf = length(coef(sarima)))
19
20 checkresiduals(sarima, lag=120)
21
22 mean(sarima$residuals)

```

B.7.8 Prévisions du modèle retenu

```

1 library(forecast)
2 prevision=forecast(sarima,h=12)
3 plot(prevision)
4
5 previsions_kt <- exp(prevision$mean)
6
7 # DF final
8 df_final <- data.frame(
9   mois_ahead = 1:12,
10   prev_kt = round(previsions_kt, 0)
11 )
12
13 print(df_final)

```